

Redes Neuronales Artificiales - Parte Tres

Técnicas de Inteligencia Artificial

Prof. Flavio Prieto
email: faprieto@unal.edu.co

INGENIERÍA MECATRONICA
Facultad de Ingeniería
Universidad Nacional de Colombia Sede Bogotá



3 de marzo de 2026

Cálculo de los Parámetros en Redes Neuronales.

- ▶ En redes neuronales, los parámetros de cada capa ℓ son:
La **matriz de pesos** $W^{[\ell]}$ y El **vector de sesgos** $b^{[\ell]}$.
- ▶ Mediante **el entrenamiento** se busca encontrar los valores óptimos de los parámetros, que:
 1. **Minimice una función de pérdida** $\mathcal{L}$, que mide la diferencia entre las salidas predichas $\hat{y}$ y las etiquetas reales y :

$$\min_{\{\text{sueto a } W^{[\ell]}, b^{[\ell]}\}} \mathcal{L}(\hat{y}, y)$$

2. **Generalice correctamente**: que obtenga buenos resultados con los datos de entrenamiento y con los datos de prueba.

Estos parámetros se calculan mediante un proceso iterativo:

1. Inicialización de $W^{[\ell]}$ y $\mathbf{b}^{[\ell]}$.
2. Propagación hacia adelante para obtener las activaciones $\mathbf{a}^{[\ell]}$:

$$\mathbf{z}^{[\ell]} = W^{[\ell]} \mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}$$

$$\mathbf{a}^{[\ell]} = \phi^{[\ell]}(\mathbf{z}^{[\ell]})$$

3. Cálculo del error mediante una función de pérdida $\mathcal{L}$.
4. Aplicación de **backpropagation** para calcular los gradientes:

$$\frac{\partial \mathcal{L}}{\partial W^{[\ell]}} \quad \text{y} \quad \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}}$$

5. Actualización de los parámetros mediante un algoritmo de optimización (por ejemplo, descenso del gradiente):


$$W^{[\ell]} := W^{[\ell]} - \eta \frac{\partial \mathcal{L}}{\partial W^{[\ell]}}$$

$$\mathbf{b}^{[\ell]} := \mathbf{b}^{[\ell]} - \eta \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}}$$

donde η es la tasa de aprendizaje.

Este ciclo se repite durante varias épocas hasta que la red minimiza el error.

Ilustración del cálculo en la neurona j de la capa ℓ .



- ▶ $\phi^{[\ell]}$: Función de activación de la neurona j en la capa ℓ .
- ▶ Se calculan los gradientes: $\frac{\partial \mathcal{L}}{\partial W^{[\ell]}}$ y $\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}}$, para actualizar los pesos $W^{[\ell]}$ y los sesgos $\mathbf{b}^{[\ell]}$.

Algoritmo Backpropagation.

- ▶ Es el algoritmo que permite a una red neuronal aprender ajustando sus pesos y sesgos para que la salida predicha $\hat{\mathbf{y}}$ se acerque más a la salida verdadera $\mathbf{y}$.
- ▶ La tarea del entrenamiento es minimizar $\mathcal{L}$ respecto a los parámetros $\{W^{[\ell]}, \mathbf{b}^{[\ell]}\}$.
- ▶ Calcula de forma eficiente los gradientes de la función de pérdida respecto a todos los parámetros.
- ▶ Utiliza la **regla de la cadena** y la estructura en capas de la red.
- ▶ Permite entrenar redes profundas con muchos parámetros.

Backpropagation: fases principales

1. Propagación hacia adelante (forward pass)

- ▶ Calcula las activaciones $\mathbf{a}^{[\ell]}$ y salidas intermedias $\mathbf{z}^{[\ell]}$ desde la entrada $\mathbf{x}$ hasta la salida final $\hat{\mathbf{y}}$.

2. Retropropagación del error (backward pass)

- ▶ Calcula los gradientes del error con respecto a cada peso y sesgo.
- ▶ Utiliza las derivadas de las funciones de activación y los errores propagados hacia atrás.

Forward pass:

$$\mathbf{z}^{[\ell]} = \mathbf{W}^{[\ell]} \mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}$$

$$\mathbf{a}^{[\ell]} = \phi^{[\ell]}(\mathbf{z}^{[\ell]})$$

- ▶ Se realiza para todas las capas desde la entrada hasta la **salida**:

$$\hat{\mathbf{y}} = \mathbf{a}^{[L]}$$

- ▶ Permite calcular el **costo** (ejemplo: cross-entropy):

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_{i=1}^C y_i \log(\hat{y}_i)$$

- ▶ La pérdida depende explícitamente de $\hat{\mathbf{y}}$.
- ▶ Permite aplicar la regla de la cadena

Backward pass:

- ▶ Se aplica la regla de la cadena para calcular los gradientes en cada capa (ℓ):

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[\ell]}} = \nabla_{\mathbf{W}^{[\ell]}} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[\ell]}} \cdot \frac{\partial \mathbf{a}^{[\ell]}}{\partial \mathbf{z}^{[\ell]}} \cdot \frac{\partial \mathbf{z}^{[\ell]}}{\partial \mathbf{W}^{[\ell]}}$$


$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}} = \nabla_{\mathbf{b}^{[\ell]}} \mathcal{L} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[\ell]}} \cdot \frac{\partial \mathbf{a}^{[\ell]}}{\partial \mathbf{z}^{[\ell]}} \cdot \frac{\partial \mathbf{z}^{[\ell]}}{\partial \mathbf{b}^{[\ell]}}$$

- ▶ Se actualizan los pesos y sesgos de la capa ℓ :


$$\mathbf{W}^{[\ell]} \leftarrow \mathbf{W}^{[\ell]} - \eta \cdot \nabla_{\mathbf{W}^{[\ell]}} \mathcal{L}$$

$$\mathbf{b}^{[\ell]} \leftarrow \mathbf{b}^{[\ell]} - \eta \cdot \nabla_{\mathbf{b}^{[\ell]}} \mathcal{L}$$


Propagación del error hacia atrás mediante la regla de la cadena.




Propagación del error hacia atrás mediante la regla de la cadena.



Propagación del error hacia atrás mediante la regla de la cadena.



Propagación del error hacia atrás mediante la regla de la cadena.



Cálculo de gradientes en la capa de salida.

Red neuronal con L capas:

- ▶ Capas ocultas: $\ell = 1, \dots, L - 1$
- ▶ Capa de salida: $\ell = L$

Notación:

$$\mathbf{z}^{[\ell]} = \mathbf{W}^{[\ell]} \mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}$$

$$\mathbf{a}^{[\ell]} = \phi^{[\ell]}(\mathbf{z}^{[\ell]})$$

- ▶ $\phi^{[L]}(\cdot) = \text{softmax}(\cdot)$
- ▶ $\mathbf{a}^{[L]} = \hat{\mathbf{y}}$: salida
 $\mathbf{a}^{[L]} \in \mathbb{R}^C$ vector columna de dimensión: $C \times 1$.
Donde C es el número de clases.
- ▶ $\mathbf{y}$: vector objetivo one-hot
- ▶ Función de costo cross-entropy: $\mathcal{L} = - \sum_{i=1}^C y_i \log \hat{y}_i$.

Aplicación de la regla de la cadena.

- ▶ La pérdida depende de $\mathbf{z}^{[L]}$ a través de:

$$\mathbf{z}^{[L]} \xrightarrow{\phi^{[L]=\text{softmax}}} \hat{\mathbf{y}} = \phi^{[L]}(\mathbf{z}^{[L]}) = \mathbf{a}^{[L]} \rightarrow \mathcal{L}$$

- ▶ Se quiere determinar:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} \cdot \frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} \cdot \frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{W}^{[L]}}$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} \cdot \frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} \cdot \frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{b}^{[L]}}$$

Primer término:

Derivada de la cross-entropy respecto a la salida estimada $\mathbf{a}^{[L]}$ (o $\hat{\mathbf{y}}$).

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} = \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{y}}} = \left[\frac{\partial \mathcal{L}}{\partial a_1^{[L]}}, \dots, \frac{\partial \mathcal{L}}{\partial a_C^{[L]}} \right]$$

- ▶ Derivando término a término:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}_i} = \frac{\partial}{\partial \hat{y}_i} \left(- \sum_{i=1}^C y_i \log \hat{y}_i \right) = -y_i \cdot \frac{1}{\hat{y}_i} = -\frac{y_i}{\hat{y}_i}$$

- ▶ En forma vectorial.

$$\frac{\partial \mathcal{L}}{\partial \hat{\mathbf{y}}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} = - \left[\frac{y_1}{\hat{y}_1}, \dots, \frac{y_i}{\hat{y}_i}, \dots, \frac{y_C}{\hat{y}_C} \right]^\top,$$

Luego:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} = -\frac{\mathbf{y}}{\hat{\mathbf{y}}}$$

Donde:

- ▶ $\frac{\mathbf{y}}{\hat{\mathbf{y}}}$ es la división elemento a elemento.
- ▶ $\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}}$ es un vector fila de dimensión $[1 \times C]$.
- ▶ C corresponde al número de neuronas de la capa de salida (número de clases).

Segundo término:

Derivada de la activación $\phi^{[L]}(\cdot)$ respecto al vector de pre-activaciones $\mathbf{z}^{[L]}$.

- ▶ La función de activación $\phi^{[L]}(\cdot)$ en la capa de salida es la función softmax($\cdot$).
- ▶ Sea la capa de salida L con C neuronas.
- ▶ La función de activación softmax se define para cada salida como:

$$a_i^{[L]} = \text{softmax}(\mathbf{z}^{[L]})_i = \frac{e^{z_i^{[L]}}}{\sum_{k=1}^C e^{z_k^{[L]}}}$$

- ▶ Se desea calcular: $\frac{\partial a_i^{[L]}}{\partial z_j^{[L]}}$

considerando los casos $i = j$ y $i \neq j$.

Derivada del Softmax en Backpropagation

- ▶ Se considera la función **softmax**:

$$a_i = \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}}$$

donde:

- ▶ z_i es el logit (entrada antes de activación),
- ▶ a_i es la probabilidad de la clase i ,
- ▶ K es el número total de clases.

- ▶ Se desea calcular:

$$\frac{\partial a_i}{\partial z_j}$$

- ▶ Observación: **Cada salida depende de todos los logits.**

Caso $i = j$

► Sea: $S = \sum_{k=1}^K e^{z_k}$

► Entonces: $a_i = \frac{e^{z_i}}{S}$

► Aplicando regla del cociente y factorizando:

$$\frac{\partial a_i}{\partial z_i} = \frac{e^{z_i} S - e^{z_i} e^{z_i}}{S^2} = \frac{e^{z_i}}{S} \left(\frac{S - e^{z_i}}{S} \right)$$

► Dado que $a_i = \frac{e^{z_i}}{S}$ se tiene:

$$\frac{\partial a_i}{\partial z_i} = a_i(1 - a_i)$$

Caso $i \neq j$

- ▶ Se tiene nuevamente: $a_i = \frac{e^{z_i}}{S}$
- ▶ El término z_j afecta únicamente al denominador S .
- ▶ Derivando:

$$\frac{\partial a_i}{\partial z_j} = \frac{0 \cdot S - e^{z_i} e^{z_j}}{S^2} = -\frac{e^{z_i}}{S} \frac{e^{z_j}}{S}$$

- ▶ Por tanto:

$$\boxed{\frac{\partial a_i}{\partial z_j} = -a_i a_j} \quad \text{cuando } i \neq j$$

Forma Compacta del Jacobiano

- ▶ Ambos casos pueden escribirse de forma unificada usando el delta de Kronecker:

$$\delta_{ij} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{si } i \neq j \end{cases}$$

- ▶ Entonces:

$$\frac{\partial a_i}{\partial z_j} = a_i(\delta_{ij} - a_j)$$

- ▶ El Jacobiano del softmax **no es diagonal**.
- ▶ Existe acoplamiento entre clases.
- ▶ Cada logit afecta a todas las probabilidades.

Interpretación del Jacobiano

- Sea una función vectorial:

$$\mathbf{a} : \mathbb{R}^C \rightarrow \mathbb{R}^C,$$

la cual recibe un vector de C variables reales y devuelve otro vector de C variables reales.

- En la capa de salida dicha función es **softmax**:

$$\mathbf{a}(\mathbf{z}) = \begin{bmatrix} a_1(\mathbf{z}) \\ a_2(\mathbf{z}) \\ \vdots \\ a_C(\mathbf{z}) \end{bmatrix},$$

donde cada componente está definida por:

$$a_i(\mathbf{z}) = \frac{e^{z_i}}{\sum_{k=1}^C e^{z_k}}.$$

- El jacobiano $J_{\mathbf{a}}(\mathbf{z})$ en el punto $\mathbf{z}$ se define como la matriz de todas las derivadas parciales:

$$J_{\mathbf{a}}(\mathbf{z}) = \begin{bmatrix} \frac{\partial a_1}{\partial z_1} & \dots & \frac{\partial a_1}{\partial z_j} & \dots & \frac{\partial a_1}{\partial z_C} \\ \vdots & \ddots & \vdots & & \vdots \\ \frac{\partial a_i}{\partial z_1} & \dots & \frac{\partial a_i}{\partial z_j} & \dots & \frac{\partial a_i}{\partial z_C} \\ \vdots & & \vdots & \ddots & \vdots \\ \frac{\partial a_C}{\partial z_1} & \dots & \frac{\partial a_C}{\partial z_j} & \dots & \frac{\partial a_C}{\partial z_C} \end{bmatrix}.$$

- Luego:

$$J_{\mathbf{a}}(\mathbf{z}^{[L]}) = \left[J_{\text{softmax}}(\mathbf{z}^{[L]}) \right]_{ij} = a_i^{[L]}(\delta_{ij} - a_j^{[L]}); \quad i, j \in \{1, \dots, C\}$$

- ▶ En notación matricial:

$$J_{\mathbf{a}}(\mathbf{z}) = \frac{\partial \mathbf{a}}{\partial \mathbf{z}} = \text{diag}(\mathbf{a}) - \mathbf{a}\mathbf{a}^T$$

- ▶ $\text{diag}(\mathbf{a})$ contiene los términos $a_i(1 - a_i)$.
- ▶ $\mathbf{a}\mathbf{a}^T$ introduce los términos $a_i a_j$.
- ▶ La activación softmax no actúa de manera independiente sobre cada componente, ya que cada salida depende de todos los z_j .
- ▶ En consecuencia, el jacobiano no es una matriz diagonal.
- ▶ Este jacobiano describe cómo, al incrementarse una de las entradas z_j , se ajustan todas las probabilidades de salida para que la suma total se mantenga igual a 1.

Tercer término:

Derivada del vector de pre-activaciones (logits) $\mathbf{z}^{[L]}$ con respecto a los pesos $W^{[L]}$ o a los sesgos $\mathbf{b}^{[L]}$.

- ▶ En la capa de salida L , las pre-activaciones están dadas por:

$$\mathbf{z}^{[L]} = W^{[L]} \mathbf{a}^{[L-1]} + \mathbf{b}^{[L]}$$

- ▶ Cada componente es:

$$z_i^{[L]} = \sum_{j=1}^{n^{[L-1]}} W_{ij}^{[L]} a_j^{[L-1]} + b_i^{[L]}$$

- ▶ Con $n^{[L-1]}$, el número de neuronas en la capa $L - 1$.

Backpropagation: Cálculo de Gradientes

- ▶ La derivada de $z_i^{[L]}$ respecto a $W_{ij}^{[L]}$ es:

$$\frac{\partial z_i^{[L]}}{\partial W_{ij}^{[L]}} = a_j^{[L-1]}$$

- ▶ En términos del vector de activaciones de la capa anterior, $\mathbf{a}^{[L-1]}$, se tiene que:

$$\frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{W}^{[L]}} = \mathbf{a}^{[L-1]}$$

- ▶ La derivada de $\mathbf{z}^{[L]}$ respecto al vector de sesgos $\mathbf{b}^{[L]}$ es:

$$\frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{b}^{[L]}} = \mathbf{I}_C$$

donde $\mathbf{I}_C$ es la matriz identidad de tamaño $C \times C$.

Regla de la cadena con respecto a los pesos W .

$$\boxed{\frac{\partial \mathcal{L}}{\partial W^{[L]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} \cdot \frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} \cdot \frac{\partial \mathbf{z}^{[L]}}{\partial W^{[L]}}}$$

- ▶ Primer término:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} = - \left[\frac{y_1}{\hat{y}_1}, \dots, \frac{y_C}{\hat{y}_C} \right] \in \mathbb{R}^{1 \times C}$$

- ▶ Segundo término:

$$\frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} = J_{\text{softmax}}(\mathbf{z}^{[L]}) = \left[a_i^{[L]} (\delta_{ij} - a_j^{[L]}) \right]_{ij} \in \mathbb{R}^{C \times C}$$

- ▶ Tercer término:

$$\frac{\partial \mathbf{z}^{[L]}}{\partial W^{[L]}} = \mathbf{a}^{[L-1]} \in \mathbb{R}^{n^{[L-1]} \times 1}$$

Backpropagation: Cálculo de Gradientes

- ▶ Se multiplica paso a paso:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} \cdot \frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} = \left(\underbrace{\boldsymbol{\delta}^{[L]}}_{1 \times C} \right)^{\top} = \underbrace{\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}}}_{1 \times C} \cdot \underbrace{J_{\text{softmax}}(\mathbf{z}^{[L]})}_{C \times C} \in \mathbb{R}^{1 \times C}$$

- ▶ $\boldsymbol{\delta}^{[L]}$ mide el “error” que se propaga hacia atrás en la red.
- ▶ Luego, de la regla de la cadena:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L]}} = \boldsymbol{\delta}^{[L]} \cdot \frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{W}^{[L]}}$$

- ▶ Como $\boldsymbol{\delta}^{[L]} \in \mathbb{R}^{C \times 1}$, se necesita trasponer a $\mathbf{a}^{[L-1]}$ para que el gradiente $\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L]}}$ sea del tamaño correcto ($\mathbb{R}^{C \times n^{[L-1]}}$).
- ▶ Finalmente, el gradiente se obtiene como:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L]}} = \boldsymbol{\delta}^{[L]} \cdot (\mathbf{a}^{[L-1]})^{\top} \in \mathbb{R}^{C \times n^{[L-1]}}.$$

Regla de la cadena con respecto a los sesgos $\mathbf{b}^{[L]}$.

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} \cdot \frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} \cdot \frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{b}^{[L]}} = \boldsymbol{\delta}^{[L]} \cdot \frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{b}^{[L]}}$$

- ▶ Dado que:

$$\frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{b}^{[L]}} = I_C,$$

- ▶ Se multiplica:

$$\boldsymbol{\delta}^{[L]} \cdot I_C = \boldsymbol{\delta}^{[L]}.$$

- ▶ Por lo tanto, el gradiente de la pérdida respecto a los sesgos se obtiene como:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L]}} = \boldsymbol{\delta}^{[L]} \in \mathbb{R}^{C \times 1}.$$

Cálculo de gradientes en las capas ocultas.

Red neuronal con L capas:

- ▶ Capas ocultas: $\ell = 1, \dots, L - 1$
- ▶ Capa de salida: $\ell = L$

Notación:

$$\mathbf{z}^{[\ell]} = \mathbf{W}^{[\ell]} \mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}$$

$$\mathbf{a}^{[\ell]} = \phi^{[\ell]}(\mathbf{z}^{[\ell]})$$

- ▶ $\phi^{[L-1]}(\cdot)$: función de activación (ejemplo: ReLU).
- ▶ $n^{[L-1]}$: número de neuronas en la capa $L - 1$.
- ▶ $n^{[L-2]}$: número de neuronas en la capa $L - 2$.

Aplicación de la regla de la cadena en la capa $L - 1$.

- ▶ La pérdida depende de $\mathbf{z}^{[L-1]}$ a través de:

$$\mathbf{z}^{[L-1]} \xrightarrow{\phi^{[L-1]}} \mathbf{a}^{[L-1]} \rightarrow \mathbf{z}^{[L]} \xrightarrow{\phi^{[L]}=\text{softmax}} \mathbf{a}^{[L]} = \hat{\mathbf{y}} \rightarrow \mathcal{L}.$$

- ▶ Se quiere determinar:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} \cdot \frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{W}^{[L-1]}}.$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} \cdot \frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{b}^{[L-1]}}.$$

Primer término: $\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}}$

- ▶ La capa $L - 1$ no está conectada directamente a la pérdida $\mathcal{L}$, pero depende indirectamente de $\mathbf{a}^{[L-1]}$ a través de:

$$\mathbf{a}^{[L-1]} \rightarrow \mathbf{z}^{[L]} = W^{[L]}\mathbf{a}^{[L-1]} + \mathbf{b}^{[L]} \xrightarrow{\phi^{[L]}=\text{softmax}} \mathbf{a}^{[L]} = \hat{\mathbf{y}} \rightarrow \mathcal{L}.$$

- ▶ Por la regla de la cadena:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} \cdot \frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} \cdot \frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{a}^{[L-1]}}.$$

Desarrollo término a término

- ▶ Primer término:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}} = -\frac{\mathbf{y}}{\hat{\mathbf{y}}} \in \mathbb{R}^{1 \times C}.$$

- ▶ Segundo término:

$$\frac{\partial \mathbf{a}^{[L]}}{\partial \mathbf{z}^{[L]}} = J_{\text{softmax}}(\mathbf{z}^{[L]}) = [a_i^{[L]}(\delta_{ij} - a_j^{[L]})]_{ij} \in \mathbb{R}^{C \times C}.$$

- ▶ Tercer término: en la capa de salida L :

$$\mathbf{z}^{[L]} = W^{[L]}\mathbf{a}^{[L-1]} + \mathbf{b}^{[L]},$$

luego:

$$\frac{\partial \mathbf{z}^{[L]}}{\partial \mathbf{a}^{[L-1]}} = W^{[L]} \in \mathbb{R}^{C \times n^{[L-1]}}.$$

Producto paso a paso

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} &= \underbrace{\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L]}}}_{1 \times C} \cdot \underbrace{J_{\text{softmax}}(\mathbf{z}^{[L]})}_{C \times C} \cdot \underbrace{W^{[L]}}_{C \times n^{[L-1]}} \\ &= (\boldsymbol{\delta}^{[L]})^\top \cdot W^{[L]}\end{aligned}$$

donde:

$$\boldsymbol{\delta}^{[L]} = J_{\text{softmax}}(\mathbf{z}^{[L]})^\top \cdot \left(-\frac{\mathbf{y}}{\hat{\mathbf{y}}}\right)^\top \in \mathbb{R}^{C \times 1}.$$

Resultado final

$$\boxed{\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} = (W^{[L]})^\top \cdot \boldsymbol{\delta}^{[L]} \in \mathbb{R}^{n^{[L-1]} \times 1}.}$$

- ▶ Este vector indica cómo la pérdida cambia respecto a cada activación de la capa $L - 1$.
- ▶ $\boldsymbol{\delta}^{[L]}$ resume el error propagado desde la capa de salida.

Segundo término:

Derivada de la activación $a^{[L-1]}(\cdot)$ respecto a $\mathbf{z}^{[L-1]}$

- ▶ La activación en la capa $L - 1$ es una función **ReLU**:

$$a_i^{[L-1]} = \max(0, z_i^{[L-1]})$$

- ▶ Derivada término a término:

$$\frac{\partial a_i^{[L-1]}}{\partial z_i^{[L-1]}} = \phi'(z_i^{[L-1]}) = \begin{cases} 1 & \text{si } z_i^{[L-1]} > 0, \\ 0 & \text{en otro caso.} \end{cases}$$

- ▶ En forma vectorial:

$$\frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} = \text{diag}(\phi'(\mathbf{z}^{[L-1]})) \in \mathbb{R}^{n^{[L-1]} \times n^{[L-1]}}.$$

Tercer término:

Derivada de $\mathbf{z}^{[L-1]}$ respecto a $\mathbf{W}^{[L-1]}$

$$\mathbf{z}^{[L-1]} = \mathbf{W}^{[L-1]}\mathbf{a}^{[L-2]} + \mathbf{b}^{[L-1]}$$

- Cada componente:

$$z_i^{[L-1]} = \sum_{j=1}^{n^{[L-2]}} W_{ij}^{[L-1]} a_j^{[L-2]} + b_i^{[L-1]}$$

- Derivada: $\frac{\partial z_i^{[L-1]}}{\partial W_{ij}^{[L-1]}} = a_j^{[L-2]}$

- En forma vectorial:

$$\frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{W}^{[L-1]}} = \mathbf{a}^{[L-2]} \in \mathbb{R}^{n^{[L-2]} \times 1}.$$

Regla de la cadena en la capa $L - 1$:

Se quiere hallar:

$$\frac{\partial \mathcal{L}}{\partial W^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} \cdot \frac{\partial \mathbf{z}^{[L-1]}}{\partial W^{[L-1]}}.$$

Se define el error:

$$\delta^{[L-1]} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \odot \phi'(\mathbf{z}^{[L-1]}),$$

- ▶ con $\odot$ denotando el producto elemento a elemento (producto de Hadamard) resultado de multiplicar un vector por una matriz diagonal.
- ▶ $\delta^{[L-1]}$ **mide cómo cambia la pérdida $\mathcal{L}$ si cambian los logits** (las entradas a la activación) $\mathbf{z}^{[L-1]}$ en la capa $L - 1$.

Producto de Hadamard en Backpropagation

El producto de Hadamard es la multiplicación elemento a elemento entre dos matrices (o vectores) de la misma dimensión.

Ejemplo del cálculo del error $\delta^{[L-1]}$, como el producto de Hadamard:

$$\delta^{[L-1]} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \odot \phi'(\mathbf{z}^{[L-1]})$$

Dado que: $\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \in \mathbb{R}^{n^{[L-1]} \times 1}$ y $\phi'(\mathbf{z}^{[L-1]}) \in \mathbb{R}^{n^{[L-1]} \times 1}$, el producto es elemento a elemento.

Ejemplo:

- ▶ Supóngase una capa con 3 neuronas: $\mathbf{z}^{[L-1]} = \begin{bmatrix} 2 \\ -1 \\ 0,5 \end{bmatrix}$
- ▶ Función de activación: ReLU $\phi(z) = \max(0, z)$
- ▶ Entonces: $\phi'(\mathbf{z}^{[L-1]}) = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$

- ▶ Suponga que: $\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} = \begin{bmatrix} 0,8 \\ -0,4 \\ 0,2 \end{bmatrix}$
- ▶ Producto de Hadamard: $\frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[L-1]}} = \begin{bmatrix} 0,8 \\ -0,4 \\ 0,2 \end{bmatrix} \odot \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0,8 \\ 0 \\ 0,2 \end{bmatrix}$

Forma con Matriz Diagonal

- ▶ Se construye la matriz diagonal con las derivadas:

$$D = \text{diag}(\phi'(\mathbf{z})) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- ▶ Por regla de la cadena:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[L-1]}} = D \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0,8 \\ -0,4 \\ 0,2 \end{bmatrix} = \begin{bmatrix} 0,8 \\ 0 \\ 0,2 \end{bmatrix}$$

- ▶ **Resultado:** Se obtiene exactamente el mismo vector que con el producto de Hadamard.

Producto exterior

Es una operación entre dos vectores que produce una matriz.

Definición

- ▶ Sean: $\mathbf{x} \in \mathbb{R}^{m \times 1}$, $\mathbf{y} \in \mathbb{R}^{n \times 1}$
- ▶ El producto exterior se define como:

$$\mathbf{xy}^T$$

y el resultado es una matriz de dimensión: $\mathbb{R}^{m \times n}$

- ▶ **A nivel de componentes**

$$(\mathbf{xy}^T)_{ij} = x_i y_j$$

donde cada entrada es simplemente:

fila i de $\mathbf{x}$ $\times$ columna j de $\mathbf{y}$

Estructura del gradiente respecto a la matriz de pesos

- ▶ La matriz gradiente tiene entradas:

$$\left(\frac{\partial \mathcal{L}}{\partial W} \right)_{ij} = \delta_i a_j$$

- ▶ **Observando la estructura:**

- ▶ Índice de fila (i) $\rightarrow$ proviene de δ_i
- ▶ Índice de columna (j) $\rightarrow$ proviene de a_j

- ▶ Esto es exactamente la definición de un **producto exterior**:

$$\boxed{\delta \mathbf{a}^\top}$$

porque

$$(\delta \mathbf{a}^\top)_{ij} = \delta_i a_j$$

Regla de la cadena en la capa $L - 1$:

- ▶ Se quiere hallar:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} \cdot \frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{W}^{[L-1]}}.$$

- ▶ Con

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[L-1]}} = \boldsymbol{\delta}^{[L-1]} \in \mathbb{R}^{n^{[L-1]} \times 1}$$

$$\frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{W}^{[L-1]}} = \mathbf{a}^{[L-2]} \in \mathbb{R}^{n^{[L-2]} \times 1}.$$

Luego: dado que $\frac{\partial \mathcal{L}}{\partial W_{ij}}$ es un producto exterior, se tiene:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L-1]}} = \boldsymbol{\delta}^{[L-1]} \Big|_{\in \mathbb{R}^{n^{[L-1]} \times 1}} \cdot (\mathbf{a}^{[L-2]})^\top \Big|_{\in \mathbb{R}^{1 \times n^{[L-2]}}} \in \mathbb{R}^{n^{[L-1]} \times n^{[L-2]}}.$$

Gradiente respecto a los sesgos en la capa $L - 1$:

Se quiere hallar:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} \cdot \frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{b}^{[L-1]}}.$$

Se sabe que:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[L-1]}} = \boldsymbol{\delta}^{[L-1]}$$

► Ahora, dado que $\mathbf{z}^{[L-1]} = W^{[L-1]}\mathbf{a}^{[L-2]} + \mathbf{b}^{[L-1]}$, entonces:

$$\frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{b}^{[L-1]}} = \mathbf{I}_{n^{[L-1]}},$$

Luego, el gradiente respecto a los sesgos es:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-1]}} = \boldsymbol{\delta}^{[L-1]} \in \mathbb{R}^{n^{[L-1]} \times 1}.$$

Resumen para la capa oculta $\ell = L - 1$.

- ▶ Cálculo de la propagación del error a la capa $L - 1$:

$$\delta^{[L-1]} = (W^{[L]})^\top \delta^{[L]} \odot \phi'(\mathbf{z}^{[L-1]}) \in \mathbb{R}^{n^{[L-1]} \times 1}$$

- ▶ Cálculo del gradiente de la pérdida con respecto a los pesos en la capa $L - 1$:

$$\frac{\partial \mathcal{L}}{\partial W^{[L-1]}} = \delta^{[L-1]} \cdot (\mathbf{a}^{[L-2]})^\top \in \mathbb{R}^{n^{[L-1]} \times n^{[L-2]}}$$

- ▶ Cálculo del gradiente de la pérdida con respecto a los sesgos en la capa $L - 1$:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-1]}} = \delta^{[L-1]} \in \mathbb{R}^{n^{[L-1]} \times 1}$$

Cálculo de gradientes en la capa $\ell = L - 2$.

Red neuronal con L capas:

- ▶ Capas ocultas: $\ell = 1, \dots, L - 1$
- ▶ Capa de salida: $\ell = L$

Notación:

$$\mathbf{z}^{[L-2]} = \mathbf{W}^{[L-2]} \mathbf{a}^{[L-3]} + \mathbf{b}^{[L-2]}$$

$$\mathbf{a}^{[L-2]} = \phi^{[L-2]}(\mathbf{z}^{[L-2]})$$

- ▶ $\phi^{[L-2]}(\cdot)$: función de activación (ejemplo: ReLU).
- ▶ $n^{[L-2]}$: número de neuronas en la capa $L - 2$.
- ▶ $n^{[L-3]}$: número de neuronas en la capa $L - 3$.

Aplicación de la regla de la cadena en la capa $L - 2$.

La pérdida depende de $\mathbf{z}^{[L-2]}$ a través de:

$$\mathbf{z}^{[L-2]} \xrightarrow{\phi^{[L-2]}} \mathbf{a}^{[L-2]} \rightarrow \mathbf{z}^{[L-1]} \xrightarrow{\phi^{[L-1]}} \mathbf{a}^{[L-1]}$$

$$\mathbf{a}^{[L-1]} \rightarrow \mathbf{z}^{[L]} \xrightarrow{\phi^{[L]}=\text{softmax}} \mathbf{a}^{[L]} = \hat{\mathbf{y}} \rightarrow \mathcal{L}.$$

Se quiere determinar:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L-2]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-2]}} \cdot \frac{\partial \mathbf{a}^{[L-2]}}{\partial \mathbf{z}^{[L-2]}} \cdot \frac{\partial \mathbf{z}^{[L-2]}}{\partial \mathbf{W}^{[L-2]}}.$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-2]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-2]}} \cdot \frac{\partial \mathbf{a}^{[L-2]}}{\partial \mathbf{z}^{[L-2]}} \cdot \frac{\partial \mathbf{z}^{[L-2]}}{\partial \mathbf{b}^{[L-2]}}.$$

Primer término: $\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-2]}}$

- ▶ La capa $L - 2$ no está conectada directamente a la pérdida $\mathcal{L}$, pero depende indirectamente de $\mathbf{a}^{[L-2]}$ a través de:

$$\mathbf{a}^{[L-2]} \rightarrow \mathbf{z}^{[L-1]} = W^{[L-1]}\mathbf{a}^{[L-2]} + \mathbf{b}^{[L-1]} \xrightarrow{\phi^{[L-1]}} \mathbf{a}^{[L-1]} \rightarrow \dots \rightarrow \mathcal{L}.$$

- ▶ Aplicando la regla de la cadena:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-2]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} \cdot \frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} \cdot \frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{a}^{[L-2]}}.$$

Desarrollo término a término

- ▶ Primer término, ya se conoce:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-1]}} = (W^{[L]})^\top \cdot \boldsymbol{\delta}^{[L]} \in \mathbb{R}^{1 \times n^{[L-1]}}.$$

- ▶ Segundo término, ya se conoce¹:

$$\frac{\partial \mathbf{a}^{[L-1]}}{\partial \mathbf{z}^{[L-1]}} = J_{\phi^{[L-1]}}(\mathbf{z}^{[L-1]}) = \text{diag}(\phi'(\mathbf{z}^{[L-1]})) \in \mathbb{R}^{n^{[L-1]} \times n^{[L-1]}}.$$

- ▶ Tercer término, dado que $\mathbf{z}^{[L-1]} = W^{[L-1]}\mathbf{a}^{[L-2]} + \mathbf{b}^{[L-1]}$, entonces:

$$\frac{\partial \mathbf{z}^{[L-1]}}{\partial \mathbf{a}^{[L-2]}} = W^{[L-1]} \in \mathbb{R}^{n^{[L-1]} \times n^{[L-2]}}.$$

¹Dado que la función de activación ϕ se aplica elemento a elemento, cada componente $a_i^{[L-1]} = \phi(z_i^{[L-1]})$ depende únicamente de su respectivo $z_i^{[L-1]}$, por tanto, el jacobiano es una **matriz diagonal**.

Producto paso a paso

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-2]}} &= \underbrace{(W^{[L]})^\top \cdot \boldsymbol{\delta}^{[L]}}_{1 \times n^{[L-1]}} \cdot \underbrace{J_{\phi^{[L-1]}}(\mathbf{z}^{[L-1]})}_{n^{[L-1]} \times n^{[L-1]}} \cdot \underbrace{W^{[L-1]}}_{n^{[L-1]} \times n^{[L-2]}} \\ &= \left(\boldsymbol{\delta}^{[L-1]} \right)^\top \cdot W^{[L-1]}.\end{aligned}$$

donde:

$$\begin{aligned}\boldsymbol{\delta}^{[L-1]} &= J_{\phi^{[L-1]}}(\mathbf{z}^{[L-1]})^\top \cdot \left((W^{[L]})^\top \cdot \boldsymbol{\delta}^{[L]} \right)^\top \in \mathbb{R}^{n^{[L-1]} \times 1}. \\ &= \text{diag}(\phi'(\mathbf{z}^{[L-1]})) \cdot (W^{[L]})^\top \boldsymbol{\delta}^{[L]} \\ &= (W^{[L]})^\top \boldsymbol{\delta}^{[L]} \odot \phi'(\mathbf{z}^{[L-1]})\end{aligned}$$

Resultado final

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-2]}} = (W^{[L-1]})^\top \cdot \boldsymbol{\delta}^{[L-1]} \in \mathbb{R}^{n^{[L-2]} \times 1}.$$

- ▶ Este vector describe cómo la pérdida cambia respecto a cada activación de la capa $L - 2$.
- ▶ $\boldsymbol{\delta}^{[L-1]}$ resume el error propagado desde la capa $L - 1$.

Segundo término: Derivada de la activación $\phi^{[L-2]}(\cdot)$

- ▶ La activación es ReLU:

$$a_i^{[L-2]} = \max(0, z_i^{[L-2]}).$$

- ▶ Derivada:

$$\phi'(z^{[L-2]}) = \begin{cases} 1 & \text{si } z_i^{[L-2]} > 0, \\ 0 & \text{en otro caso.} \end{cases}$$

- ▶ En forma vectorial:

$$\frac{\partial \mathbf{a}^{[L-2]}}{\partial \mathbf{z}^{[L-2]}} = \text{diag}(\phi'(\mathbf{z}^{[L-2]})) \in \mathbb{R}^{n^{[L-2]} \times n^{[L-2]}}.$$

Tercer término: Derivada de $\mathbf{z}^{[L-2]}$ respecto a $\mathbf{W}^{[L-2]}$

$$\mathbf{z}^{[L-2]} = \mathbf{W}^{[L-2]} \mathbf{a}^{[L-3]} + \mathbf{b}^{[L-2]}.$$

- Cada componente:

$$z_i^{[L-2]} = \sum_{j=1}^{n^{[L-3]}} w_{ij}^{[L-2]} a_j^{[L-3]} + b_i^{[L-2]}.$$

- Derivada:

$$\frac{\partial z_i^{[L-2]}}{\partial w_{ij}^{[L-2]}} = a_j^{[L-3]}.$$

- En forma vectorial:

$$\frac{\partial \mathbf{z}^{[L-2]}}{\partial \mathbf{W}^{[L-2]}} = \mathbf{a}^{[L-3]}.$$

Gradiente respecto a los pesos en la capa $L - 2$:

Se tiene:

$$\delta^{[L-2]} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[L-2]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[L-2]}} \odot \phi'(\mathbf{z}^{[L-2]}).$$

Entonces:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L-2]}} = \delta^{[L-2]} \cdot (\mathbf{a}^{[L-3]})^\top$$

► $\delta^{[L-2]} \in \mathbb{R}^{n^{[L-2]} \times 1}$

► $\mathbf{a}^{[L-3]} \in \mathbb{R}^{n^{[L-3]} \times 1}$

$$\Rightarrow \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L-2]}} \in \mathbb{R}^{n^{[L-2]} \times n^{[L-3]}}.$$

Gradiente respecto a los sesgos en la capa $L - 2$:

$$\mathbf{z}^{[L-2]} = \mathbf{W}^{[L-2]}\mathbf{a}^{[L-3]} + \mathbf{b}^{[L-2]}$$
$$\frac{\partial \mathbf{z}^{[L-2]}}{\partial \mathbf{b}^{[L-2]}} = \mathbf{I}_{n^{[L-2]}}.$$

Entonces:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-2]}} = \boldsymbol{\delta}^{[L-2]} \in \mathbb{R}^{n^{[L-2]} \times 1}.$$

Resumen para la capa oculta $\ell = L - 2$.

- Propagación del error:

$$\delta^{[L-2]} = (W^{[L-1]})^\top \delta^{[L-1]} \odot \phi'(\mathbf{z}^{[L-2]})$$

- Gradiente respecto a los pesos:

$$\frac{\partial \mathcal{L}}{\partial W^{[L-2]}} = \delta^{[L-2]} \cdot (\mathbf{a}^{[L-3]})^\top.$$

- Gradiente respecto a los sesgos:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-2]}} = \delta^{[L-2]}.$$

Cálculo detallado de gradientes en una capa oculta ℓ .

Red neuronal con L capas:

- ▶ Capas ocultas: $\ell = 1, \dots, L - 1$
- ▶ Capa de salida: $\ell = L$

Notación en la capa ℓ :

$$\mathbf{z}^{[\ell]} = \mathbf{W}^{[\ell]} \mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}$$

$$\mathbf{a}^{[\ell]} = \phi^{[\ell]}(\mathbf{z}^{[\ell]})$$

- ▶ $\phi^{[\ell]}(\cdot)$: función de activación (ejemplo: ReLU o sigmoide).
- ▶ $n^{[\ell]}$: número de neuronas en la capa ℓ .
- ▶ $n^{[\ell-1]}$: número de neuronas en la capa $\ell - 1$.

Aplicación de la regla de la cadena en la capa ℓ .

La pérdida $\mathcal{L}$ depende de $\mathbf{z}^{[\ell]}$ de forma indirecta:

$$\mathbf{z}^{[\ell]} \xrightarrow{\phi^{[\ell]}} \mathbf{a}^{[\ell]} \rightarrow \mathbf{z}^{[\ell+1]} \xrightarrow{\phi^{[\ell+1]}} \dots \rightarrow \mathbf{a}^{[L]} = \hat{\mathbf{y}} \rightarrow \mathcal{L}.$$

Se quiere determinar:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[\ell]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[\ell]}} \cdot \frac{\partial \mathbf{a}^{[\ell]}}{\partial \mathbf{z}^{[\ell]}} \cdot \frac{\partial \mathbf{z}^{[\ell]}}{\partial \mathbf{W}^{[\ell]}}.$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[\ell]}} \cdot \frac{\partial \mathbf{a}^{[\ell]}}{\partial \mathbf{z}^{[\ell]}} \cdot \frac{\partial \mathbf{z}^{[\ell]}}{\partial \mathbf{b}^{[\ell]}}.$$

Primer término: $\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[\ell]}}$

- ▶ La capa ℓ no está directamente conectada a la pérdida, sino que afecta a $\mathcal{L}$ a través de las capas siguientes.
- ▶ Por la regla de la cadena, se obtiene:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[\ell]}} = (W^{[\ell+1]})^\top \boldsymbol{\delta}^{[\ell+1]}.$$

- ▶ Donde:

$$\boldsymbol{\delta}^{[\ell+1]} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[\ell+1]}}$$

resume el error propagado desde la capa $\ell + 1$.

Segundo término: Derivada de la activación $\phi^{[\ell]}(\cdot)$

- ▶ Cada activación depende solo de su entrada:

$$a_i^{[\ell]} = \phi^{[\ell]}(z_i^{[\ell]}).$$

- ▶ Su derivada:

$$\frac{\partial a_i^{[\ell]}}{\partial z_i^{[\ell]}} = \phi'^{[\ell]}(z_i^{[\ell]}).$$

- ▶ En forma vectorial:

$$\frac{\partial \mathbf{a}^{[\ell]}}{\partial \mathbf{z}^{[\ell]}} = \text{diag}(\phi'^{[\ell]}(\mathbf{z}^{[\ell]})) \in \mathbb{R}^{n^{[\ell]} \times n^{[\ell]}}.$$

Tercer término: Derivada de $\mathbf{z}^{[\ell]}$ respecto a $W^{[\ell]}$

$$\mathbf{z}^{[\ell]} = W^{[\ell]} \mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}.$$

- Cada componente:

$$z_i^{[\ell]} = \sum_{j=1}^{n^{[\ell-1]}} W_{ij}^{[\ell]} a_j^{[\ell-1]} + b_i^{[\ell]}.$$

- Derivada:

$$\frac{\partial z_i^{[\ell]}}{\partial W_{ij}^{[\ell]}} = a_j^{[\ell-1]}.$$

- En forma matricial:

$$\frac{\partial \mathbf{z}^{[\ell]}}{\partial W^{[\ell]}} = \mathbf{a}^{[\ell-1]}.$$

Definición del error en la capa ℓ :

$$\delta^{[\ell]} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{[\ell]}} = \frac{\partial \mathcal{L}}{\partial \mathbf{a}^{[\ell]}} \odot \phi'^{[\ell]}(\mathbf{z}^{[\ell]}).$$

- ▶ El vector $\delta^{[\ell]} \in \mathbb{R}^{n^{[\ell]} \times 1}$ indica cómo cambia la pérdida si se alteran los logits en la capa ℓ .

Entonces, el gradiente respecto a los pesos:

$$\frac{\partial \mathcal{L}}{\partial W^{[\ell]}} = \delta^{[\ell]} \cdot (\mathbf{a}^{[\ell-1]})^\top.$$

Gradiente respecto a los sesgos en la capa ℓ :

$$\mathbf{z}^{[\ell]} = W^{[\ell]} \mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}.$$

$$\frac{\partial \mathbf{z}^{[\ell]}}{\partial \mathbf{b}^{[\ell]}} = \mathbf{I}_{n^{[\ell]}}.$$

Entonces:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}} = \boldsymbol{\delta}^{[\ell]} \in \mathbb{R}^{n^{[\ell]} \times 1}.$$

Resumen general para la capa ℓ .

- ▶ Propagación del error:

$$\delta^{[\ell]} = (W^{[\ell+1]})^\top \delta^{[\ell+1]} \odot \phi'^{[\ell]}(\mathbf{z}^{[\ell]}).$$

- ▶ Gradiente respecto a los pesos:

$$\frac{\partial \mathcal{L}}{\partial W^{[\ell]}} = \delta^{[\ell]} \cdot (\mathbf{a}^{[\ell-1]})^\top.$$

- ▶ Gradiente respecto a los sesgos:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}} = \delta^{[\ell]}.$$

Algoritmo de backpropagation: Visión General.

El algoritmo de backpropagation permite calcular de forma eficiente los gradientes de la función de pérdida $\mathcal{L}$ con respecto a todos los parámetros de la red (pesos y sesgos), siguiendo dos fases principales:

1. Fase de forward:

- ▶ Se calculan las activaciones $\mathbf{a}^{[\ell]}$ para cada capa ℓ , desde la entrada hasta la capa de salida.

2. Fase de backward:

- ▶ Se calculan los errores $\delta^{[\ell]}$ propagando el error desde la capa de salida hacia las capas ocultas.
- ▶ A partir de estos errores, se obtienen los gradientes necesarios para actualizar los pesos y sesgos.

Fase de backward: cálculo de errores

Para cada capa ℓ (de salida a entrada):

- ▶ Se calcula el error en la capa ℓ :

$$\delta^{[\ell]} = (W^{[\ell+1]})^\top \delta^{[\ell+1]} \odot \phi'^{[\ell]}(\mathbf{z}^{[\ell]}).$$

- ▶ Donde:
 - ▶ $\delta^{[\ell+1]}$: error de la capa siguiente.
 - ▶ $\phi'^{[\ell]}(\mathbf{z}^{[\ell]})$: derivada de la función de activación de la capa ℓ .
- ▶ Este error indica cómo la pérdida cambia respecto a los logits $\mathbf{z}^{[\ell]}$ de la capa ℓ .

Cálculo de gradientes

A partir del error $\delta^{[\ell]}$ en la capa ℓ , se calculan los gradientes:

- ▶ Gradiente de la pérdida respecto a los pesos:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[\ell]}} = \delta^{[\ell]} \cdot (\mathbf{a}^{[\ell-1]})^\top.$$

- ▶ Gradiente de la pérdida respecto a los sesgos:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}} = \delta^{[\ell]}.$$

Estos gradientes permiten ajustar los parámetros de la red para reducir la pérdida en la siguiente iteración.

Actualización de pesos y sesgos

- ▶ Una vez obtenidos los gradientes, se actualizan los parámetros de la red (usualmente con descenso del gradiente):

$$W^{[\ell]} \leftarrow W^{[\ell]} - \eta \cdot \frac{\partial \mathcal{L}}{\partial W^{[\ell]}}$$

$$\mathbf{b}^{[\ell]} \leftarrow \mathbf{b}^{[\ell]} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}}$$

- ▶ η : tasa de aprendizaje.
- ▶ Estas actualizaciones se realizan para todas las capas $\ell = 1, \dots, L$.

Resumen del algoritmo de backpropagation

1. Realizar una pasada forward para calcular todas las activaciones:

$$\mathbf{a}^{[\ell]} = \phi^{[\ell]}(W^{[\ell]}\mathbf{a}^{[\ell-1]} + \mathbf{b}^{[\ell]}).$$

2. Calcular el error en la capa de salida:

$$\delta^{[L]} = \nabla_{\mathbf{z}^{[L]}} \mathcal{L}.$$

3. Propagar el error hacia atrás para cada capa $\ell = L - 1, \dots, 1$:

$$\delta^{[\ell]} = (W^{[\ell+1]})^\top \delta^{[\ell+1]} \odot \phi'^{[\ell]}(\mathbf{z}^{[\ell]}).$$


4. Calcular gradientes:

$$\frac{\partial \mathcal{L}}{\partial W^{[\ell]}} = \delta^{[\ell]} \cdot (\mathbf{a}^{[\ell-1]})^\top, \quad \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}} = \delta^{[\ell]}.$$

5. Actualizar pesos y sesgos:


$$W^{[\ell]} \leftarrow W^{[\ell]} - \eta \cdot \frac{\partial \mathcal{L}}{\partial W^{[\ell]}}, \quad \mathbf{b}^{[\ell]} \leftarrow \mathbf{b}^{[\ell]} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}}.$$

Resumen visual: un ciclo del algoritmo de backpropagation




$$\mathbf{z}^{[1]} = \mathbf{W}^{[1]}\mathbf{a}^{[0]} + \mathbf{b}^{[1]}$$
$$\mathbf{a}^{[1]} = \phi(\mathbf{z}^{[1]})$$

Resumen visual: un ciclo del algoritmo de backpropagation




$$\mathbf{z}^{[2]} = \mathbf{W}^{[2]}\mathbf{a}^{[1]} + \mathbf{b}^{[2]}$$
$$\mathbf{a}^{[2]} = \phi(\mathbf{z}^{[2]})$$

Resumen visual: un ciclo del algoritmo de backpropagation




$$\mathbf{z}^{[L]} = \mathbf{W}^{[L]}\mathbf{a}^{[L-1]} + \mathbf{b}^{[L]}$$
$$\hat{\mathbf{y}} = \phi^{[L]}(\mathbf{z}^{[L]})$$

Resumen visual: un ciclo del algoritmo de backpropagation




$$\begin{aligned}\delta^{[L]} &= J_{\text{softmax}}(\mathbf{z}^{[L]})^\top \cdot \left(-\frac{\mathbf{y}}{\hat{\mathbf{y}}}\right)^\top \\ \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{[L]}} &= \delta^{[L]} \cdot (\mathbf{a}^{[L-1]})^\top \\ \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L]}} &= \delta^{[L]}\end{aligned}$$

Resumen visual: un ciclo del algoritmo de backpropagation




$$\begin{aligned}\delta^{[L-1]} &= \phi'(\mathbf{z}^{[L-1]}) \odot ((W^{[L]})^\top \cdot \delta^{[L]}) \\ \frac{\partial \mathcal{L}}{\partial W^{[L-1]}} &= \delta^{[L-1]} \cdot (\mathbf{a}^{[L-2]})^\top \\ \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-1]}} &= \delta^{[L-1]}\end{aligned}$$

Resumen visual: un ciclo del algoritmo de backpropagation



$$\begin{aligned}\delta^{[L-2]} &= \phi'(\mathbf{z}^{[L-2]}) \odot ((W^{[L-1]})^\top \cdot \delta^{[L-1]}) \\ \frac{\partial \mathcal{L}}{\partial W^{[L-2]}} &= \delta^{[L-2]} \cdot (\mathbf{a}^{[L-3]})^\top \\ \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[L-2]}} &= \delta^{[L-2]}\end{aligned}$$

Ejemplo Numérico (simplificado).



Definición de la red:

- ▶ Arquitectura: $[2, 3, 3, 2]$
- ▶ Activación en capas ocultas: ReLU
- ▶ Activación en capa de salida: Lineal $\phi(z) = z$
- ▶ Función de pérdida: $\mathcal{L} = \frac{1}{2} \|\hat{\mathbf{y}} - \mathbf{y}\|^2$
- ▶ Tasa de aprendizaje: $\eta = 0,1$

Backpropagation: Ejemplo Numérico

Entrada: $\mathbf{x} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$

Pesos y sesgos iniciales:

$$\mathbf{W}^{[1]} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ -1 & 0 \end{bmatrix}, \quad \mathbf{b}^{[1]} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\mathbf{W}^{[2]} = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix}, \quad \mathbf{b}^{[2]} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\mathbf{W}^{[3]} = \begin{bmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \end{bmatrix}, \quad \mathbf{b}^{[3]} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Forward: capa oculta 1.

$$\begin{aligned} \mathbf{z}^{[1]} &= \mathbf{W}^{[1]}\mathbf{x} + \mathbf{b}^{[1]} \\ &= \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \\ -1 \end{bmatrix} \end{aligned}$$

Activación ReLU:

$$\mathbf{a}^{[1]} = \text{ReLU}(\mathbf{z}^{[1]}) = \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix}$$

Forward: capa oculta 2.

$$\mathbf{z}^{[2]} = \mathbf{W}^{[2]}\mathbf{a}^{[1]} + \mathbf{b}^{[2]} = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 0 \\ 2 \end{bmatrix}$$

Activación ReLU:

$$\mathbf{a}^{[2]} = \begin{bmatrix} 2 \\ 0 \\ 2 \end{bmatrix}$$

Forward: capa de salida.

$$\mathbf{z}^{[3]} = \mathbf{W}^{[3]}\mathbf{a}^{[2]} + \mathbf{b}^{[3]} = \begin{bmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} 0 \\ -2 \end{bmatrix}$$

Como la función de activación es lineal, la salida predicha es:

$$\hat{\mathbf{y}} = \begin{bmatrix} 0 \\ -2 \end{bmatrix}$$

Backprop: capa de salida.

Ecuación general del error en la capa de salida:

$$\delta^{[L]} = \nabla_{\hat{\mathbf{y}}} \mathcal{L} \odot \phi^{[L]'}(\mathbf{z}^{[L]})$$

- Derivada de la pérdida cuadrática $\mathcal{L} = \frac{1}{2} \|\hat{\mathbf{y}} - \mathbf{y}\|^2$:

$$\nabla_{\hat{\mathbf{y}}} \mathcal{L} = \hat{\mathbf{y}} - \mathbf{y}$$

- Derivada de la activación lineal ($\phi'(z) = 1$):

$$\phi^{[3]'}(\mathbf{z}^{[3]}) = 1$$

Entonces:

$$\delta^{[3]} = (\hat{\mathbf{y}} - \mathbf{y}) \odot 1 = \hat{\mathbf{y}} - \mathbf{y}$$

Cálculo numérico del error en la capa de salida

Valor real:

$$\mathbf{y} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}$$

Salida predicha:

$$\hat{\mathbf{y}} = \begin{bmatrix} 0 \\ -2 \end{bmatrix}$$

Entonces:

$$\delta^{[3]} = \hat{\mathbf{y}} - \mathbf{y} = \begin{bmatrix} 0 - 2 \\ -2 - (-2) \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$$

Backprop: en las capas de ocultas.

Ecuación General del Backpropagation

Partiendo del error en la capa de salida $\delta^{[3]}$:

$$\delta^{[\ell]} = \left(W^{[\ell+1]\top} \delta^{[\ell+1]} \right) \odot \phi^{[\ell]'} \left(\mathbf{z}^{[\ell]} \right)$$

Para la ReLU $\phi(z) = \max(0, z)$, la **derivada** es:

$$\phi'(z) = \begin{cases} 1 & \text{si } z > 0 \\ 0 & \text{si } z < 0 \end{cases}.$$

En $z = 0$ la derivada no está definida pero en la práctica se toma $\phi'(0) = 0$.

Backprop: capa oculta 2.

$$\delta^{[2]} = \left(W^{[3]\top} \delta^{[3]} \right) \odot \phi'^{[2]'} \left(\mathbf{z}^{[2]} \right)$$

Dado que:

$$(W^{[3]})^\top \delta^{[3]} = \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} -2 \\ 0 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}$$

$$\phi'(\mathbf{z}^{[2]}) = \phi' \left(\begin{bmatrix} 2 \\ 0 \\ 2 \end{bmatrix} \right) = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

Entonces:

$$\delta^{[2]} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix} \odot \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}$$

Backprop: capa oculta 1.

$$\delta^{[1]} = \left(W^{[2]\top} \delta^{[2]} \right) \odot \phi'^{[1]'} \left(\mathbf{z}^{[1]} \right)$$

Dado que:

$$(W^{[2]})^\top \delta^{[2]} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \\ -1 & 1 & 0 \end{bmatrix} \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} 0 \\ -2 \\ 2 \end{bmatrix}$$

$$\phi'(z^{[1]}) = \phi' \left(\begin{bmatrix} 2 \\ -1 \\ -1 \end{bmatrix} \right) = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$$

Entonces:

$$\delta^{[1]} = \begin{bmatrix} 0 \\ -2 \\ -2 \end{bmatrix} \odot \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Gradientes de los Parámetros

$$\frac{\partial \mathcal{L}}{\partial W^{[\ell]}} = \delta^{[\ell]} \cdot (\mathbf{a}^{[\ell-1]})^\top; \quad \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}} = \delta^{[\ell]}$$

Gradientes: capa de salida.

Entrada de la capa: $\mathbf{a}^{[2]} = \begin{bmatrix} 2 \\ 0 \\ 2 \end{bmatrix}$

$$\frac{\partial \mathcal{L}}{\partial W^{[3]}} = \nabla_{W^{[3]}} \mathcal{L} = \delta^{[3]} \cdot (\mathbf{a}^{[2]})^\top = \begin{bmatrix} -2 \\ 0 \end{bmatrix} \begin{bmatrix} 2 & 0 & 2 \end{bmatrix} = \begin{bmatrix} -4 & 0 & -4 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[3]}} = \nabla_{\mathbf{b}^{[3]}} \mathcal{L} = \delta^{[3]} = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$$

Gradientes: capa oculta 2.

Entrada de la capa: $\mathbf{a}^{[1]} = \begin{bmatrix} 2 \\ 0 \\ 0 \end{bmatrix}$

$$\nabla_{W^{[2]}} \mathcal{L} = \boldsymbol{\delta}^{[2]} \cdot (\mathbf{a}^{[1]})^T = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 \end{bmatrix} = \begin{bmatrix} -4 & 0 & 0 \\ 0 & 0 & 0 \\ 4 & 0 & 0 \end{bmatrix}$$

$$\nabla_{\mathbf{b}^{[2]}} \mathcal{L} = \boldsymbol{\delta}^{[2]} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}$$

Gradientes: capa oculta 1.

Entrada de la capa: $\mathbf{x} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$

$$\nabla_{W^{[1]}} \mathcal{L} = \boldsymbol{\delta}^{[1]} \cdot (\mathbf{x})^\top = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & -1 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

$$\nabla_{\mathbf{b}^{[1]}} \mathcal{L} = \boldsymbol{\delta}^{[1]} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Actualización de pesos y sesgos

$$W^{[\ell]} \leftarrow W^{[\ell]} - \eta \cdot \frac{\partial \mathcal{L}}{\partial W^{[\ell]}}$$

$$\mathbf{b}^{[\ell]} \leftarrow \mathbf{b}^{[\ell]} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \mathbf{b}^{[\ell]}}$$

Actualización de la capa de salida.

Tasa de aprendizaje: $\eta = 0,1$

$$W^{[3]} \leftarrow W^{[3]} - \eta \cdot \nabla_{W^{[3]}} = \begin{bmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \end{bmatrix} - 0,1 \cdot \begin{bmatrix} -4 & 0 & -4 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 1,4 & 0 & -0,6 \\ -1 & 1 & 0 \end{bmatrix}$$

$$\mathbf{b}^{[3]} \leftarrow \mathbf{b}^{[3]} - \eta \cdot \nabla_{\mathbf{b}^{[3]}} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} - 0,1 \cdot \begin{bmatrix} -2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0,2 \\ 0 \end{bmatrix}$$

Actualización: capa oculta 2.

$$W^{[2]} \leftarrow W^{[2]} - \eta \cdot \nabla_{W^{[2]}} = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} - 0,1 \cdot \begin{bmatrix} -4 & 0 & 0 \\ 0 & 0 & 0 \\ 4 & 0 & 0 \end{bmatrix}$$

$$= \begin{bmatrix} 1,4 & 0 & -1 \\ 0 & 1 & 1 \\ 0,6 & -1 & 0 \end{bmatrix}$$

$$\mathbf{b}^{[2]} \leftarrow \mathbf{b}^{[2]} - \eta \cdot \nabla_{\mathbf{b}^{[2]}} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - 0,1 \cdot \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} 0,2 \\ 0 \\ -0,2 \end{bmatrix}$$

Actualización: capa oculta 1.

$$W^{[1]} \leftarrow W^{[1]} - \eta \cdot \nabla_{W^{[1]}} = W^{[1]}$$

$$\mathbf{b}^{[1]} \leftarrow \mathbf{b}^{[1]} - \eta \cdot \nabla_{\mathbf{b}^{[1]}} = \mathbf{b}^{[1]}$$

Sin cambios, pues los gradientes son ceros.

Conclusión:

- ▶ Backpropagation es una aplicación estructurada de la regla de la cadena.
- ▶ Hace posible entrenar redes neuronales profundas (Deep Learning).
- ▶ El producto matricial propaga dependencias entre capas.
- ▶ El producto de Hadamard aplica derivadas locales.
- ▶ Permite calcular todos los gradientes en tiempo proporcional al número de parámetros.

Gracias por su atención.

